

数理统计

☼ Checkbox	学会有笔记
🕒 level	本科
🕒 分支	概率统计

推荐教材

Statistical Inference (George Casella, Roger L. Berger) (chapter5-9)

统计推断基础

随机样本基本概念

随机样本和统计量

- **随机样本**：若随机变量 $X_1, X_2, \dots, X_n$ 满足：

1. 相互独立
2. 具有相同的边际分布 $f(x)$

则称其为来自总体 $f(x)$ 的**独立同分布 (iid) 随机样本**，大小为 n 。其**联合密度**：

$$f(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$$

有放回抽样满足iid条件；无放回抽样（简单随机抽样）中各 X_i 不独立，但当总体规模 N 远大于样本量 n 时，可近似视为独立。

- **统计量**：样本的任意函数 $T = T(X_1, X_2, \dots, X_n)$ ，只依赖于样本数据，不涉及总体参数，其概率分布称为**抽样分布**，可用于推断总体。

矩型统计量

- **样本均值**：数据的平均值， $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。
- **样本方差**：数据的离散程度， $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。（分母为 $n-1$ 保证无偏性）

- **样本原点矩**：以原点为基准的矩， $m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 。
- **样本中心矩**：以均值为基准的矩， $\mu_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 。
- **样本均值统计量的性质**：设总体均值为 μ ，方差为 σ^2 ，则：

$$E\bar{X} = \mu, \quad \text{Var}\bar{X} = \frac{\sigma^2}{n}, \quad ES^2 = \sigma^2$$

顺序统计量

将样本观测值从小到大排列： $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$

- **样本中位数**：排序后中间位置的值：

$$M = \begin{cases} X_{((n+1)/2)} & n \text{ 为奇数} \\ \frac{1}{2} (X_{(n/2)} + X_{(n/2+1)}) & n \text{ 为偶数} \end{cases}$$

- **第 j 个顺序统计量的密度**：

$$f_{X_{(j)}}(x) = \frac{n!}{(j-1)!(n-j)!} [F(x)]^{j-1} [1 - F(x)]^{n-j} f(x)$$

- **两个顺序统计量的联合密度**：

$$f_{X_{(i)}, X_{(j)}}(u, v) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(u)]^{i-1} [F(v) - F(u)]^{j-i-1} [1 - F(v)]^{n-j} f(u) f(v), \text{ 其中 } -\infty < u < v < \infty, 1 \leq i < j \leq n.$$

- **样本极差**： $R = X_{(n)} - X_{(1)}$ ，反映样本的分散程度。

- **经验分布函数**：

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(X_i \leq x)$$

$$F_n(x) \xrightarrow{P} F(x) \quad \text{对每个 } x$$

- **均匀分布的顺序统计量**：若 $X_1, \dots, X_n \sim \text{Uniform}(0, 1)$ ，则：

$$X_{(j)} \sim \text{Beta}(j, n - j + 1), \quad EX_{(j)} = \frac{j}{n+1}$$

收敛概念

三种收敛类型

- **依概率收敛**： $\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0$
 - 理解：偏差超过 ε 的概率趋于 0

- 关键词：**一致性**
 - 代表定理：**弱大数定律 WLLN** $\bar{X}_n \xrightarrow{P} \mu$
 - 几乎处处收敛： $P(\lim_{n \rightarrow \infty} |X_n - X| < \varepsilon) = 1$
 - 理解：几乎所有**样本路径**本身收敛（更强）
 - 与上者区别：极限符号在 $P(\cdot)$ **里面** vs **外面**
 - 代表定理：**强大数定律 SLLN** $\bar{X}_n \xrightarrow{a.s.} \mu$
 - 依分布收敛： $\lim_{n \rightarrow \infty} F_{X_n}(x) = F_X(x)$
 - 理解：**CDF** 收敛，不是随机变量本身收敛（最弱）
 - 代表定理：**中心极限定理 CLT** $\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0, 1)$
 - 配套工具：**Slutsky 定理** — 可将依概率收敛的量"插入"依分布结论
- $$X_n \xrightarrow{d} X, \quad Y_n \xrightarrow{P} a \implies X_n + Y_n \xrightarrow{d} X + a$$

蕴含关系

a.s. 收敛 $\longrightarrow$ 依概率收敛 $\longrightarrow$ 依分布收敛

Delta 方法

核心思想：Delta方法 = 用 **Taylor 展开**把 **CLT** 推广到函数上。

- 一阶 Delta 方法

条件： $\sqrt{n}(Y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$, $g'(\theta)$ 存在且不为零

结论： $\sqrt{n}[g(Y_n) - g(\theta)] \xrightarrow{d} N(0, \sigma^2[g'(\theta)]^2)$

- 二阶 Delta 方法

条件：同上，但 $g'(\theta) = 0$, $g''(\theta)$ 存在且不为零

结论： $n[g(Y_n) - g(\theta)] \xrightarrow{d} \frac{\sigma^2 g''(\theta)}{2} \chi_1^2$

一阶项消失后，需用二阶项捕捉分布行为，极限不再是正态分布。

- 多元 Delta 方法

条件： $\sqrt{n}(\mathbf{T}_n - \boldsymbol{\mu}) \xrightarrow{d} N(\mathbf{0}, \boldsymbol{\Sigma})$, $g: \mathbb{R}^k \rightarrow \mathbb{R}$ 有连续偏导数

结论： $\sqrt{n}[g(\mathbf{T}_n) - g(\boldsymbol{\mu})] \xrightarrow{d} N(0, \tau^2)$

其中方差为： $\tau^2 = \sum_i \sum_j \sigma_{ij} \frac{\partial g}{\partial \mu_i} \frac{\partial g}{\partial \mu_j} = \nabla g(\boldsymbol{\mu})^\top \boldsymbol{\Sigma} \nabla g(\boldsymbol{\mu})$

三种形式对比

	一阶	二阶	多元
条件	$g'(\theta) \neq 0$	$g'(\theta) = 0$	$\nabla g \neq \mathbf{0}$
极限分布	正态	χ_1^2 的线性变换	正态
收敛速度	$1/\sqrt{n}$	$1/n$	$1/\sqrt{n}$

抽样分布

核心问题：从正态总体推断参数

正态推断的核心只有两件事：

估计均值 μ 和估计方差 σ^2 估计均值 μ 和估计方差 σ^2

三个抽样分布，都是围绕这两件事展开的：

分布	解决的问题	核心角色
$\chi^2(k)$	σ^2 本身长什么样？	描述方差的估计量 S^2
$t(k)$	σ 未知时如何推断 μ ？	替代 Z 检验
$F(k_1, k_2)$	两组 σ^2 是否相等？	比较两个 S^2

卡方分布 $\chi^2(k)$

- 构造： $X = \sum_{i=1}^k Z_i^2 \sim \chi^2(k)$ ，其中 $Z_1, \dots, Z_k \stackrel{iid}{\sim} N(0, 1)$ 。

$$\mid (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$$

- 形状直觉： k 小的时候严重右偏； k 大的时候趋向正态分布。

- 密度函数：

$$f(x) = \frac{1}{\Gamma(k/2) \cdot 2^{k/2}} x^{k/2-1} e^{-x/2}, \quad x > 0$$

- 期望与方差： $EX = k$ ， $\text{Var}X = 2k$

- **可加性**：若 $X_1 \sim \chi^2(p)$ ， $X_2 \sim \chi^2(q)$ 且相互独立，则 $X_1 + X_2 \sim \chi^2(p + q)$

t 分布 $t(k)$

- **构造**： $T = \frac{Z}{\sqrt{X/k}} \sim t(k)$ ，其中 $Z \sim N(0, 1)$ ， $X \sim \chi^2(k)$ ，且二者独立。

$$\left| \begin{array}{ll} Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) & \leftarrow \text{真实标准化 } (\sigma \text{ 已知}) \\ \frac{X}{k} = \frac{S^2}{\sigma^2} \sim \frac{\chi^2(n-1)}{n-1} & \leftarrow \text{用样本方差估计总体方差} \\ T = \frac{Z}{\sqrt{X/k}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) & \leftarrow \sigma \text{ 未知时的标准化} \end{array} \right.$$

- **形状直觉**： k 小的时候，对 σ 的估计越不准，尾部更厚； k 大的时候趋向标准正态分布。
- **密度函数**：
$$f_T(t) = \frac{\Gamma(\frac{k+1}{2})}{\sqrt{k\pi} \Gamma(\frac{k}{2})} \left(1 + \frac{t^2}{k}\right)^{-\frac{k+1}{2}}, \quad -\infty < t < \infty$$
- **期望与方差**： $ET = 0$ ($k > 1$)， $\text{Var}T = \frac{k}{k-2}$ ($k > 2$)
- **极限性质**：当 $k \rightarrow \infty$ 时， $t(k) \rightarrow N(0, 1)$

F 分布 $F(k_1, k_2)$

- **构造**： $F = \frac{X_1/k_1}{X_2/k_2} \sim F(k_1, k_2)$ ，其中 $X_1 \sim \chi^2(k_1)$ ， $X_2 \sim \chi^2(k_2)$ ，且二者独立。
- **密度函数**：
$$f(x) = \frac{\Gamma(\frac{k_1+k_2}{2})}{\Gamma(\frac{k_1}{2})\Gamma(\frac{k_2}{2})} \left(\frac{k_1}{k_2}\right)^{k_1/2} \frac{x^{k_1/2-1}}{\left(1 + \frac{k_1}{k_2}x\right)^{(k_1+k_2)/2}}, \quad x > 0$$
- **重要性质**：
 - 若 $X \sim F(p, q)$ ，则 $1/X \sim F(q, p)$
 - 若 $X \sim t(q)$ ，则 $X^2 \sim F(1, q)$
 - 若 $X \sim F(p, q)$ ，则 $\frac{(p/q)X}{1+(p/q)X} \sim \text{Beta}(p/2, q/2)$

常用分布恒等式 (Poisson-Gamma)

若 $Y \sim \text{Poisson}(\lambda)$ ，则存在以下恒等式：

$$P(Y \leq y) = P(\chi^2_{2(y+1)} > 2\lambda)$$

$$P(Y \geq y) = P(\chi^2_{2y} < 2\lambda)$$

直觉理解： Poisson 分布的累积概率可以用 χ^2 分布的尾概率来表达，这源于 Poisson 过程与 Gamma 分布之间的深层联系（等待时间服从 Gamma 分布）。

数据缩减：充分性原则

任意统计量 $T(X)$ 都定义了一种数据缩减方式。

充分统计量

- **定义：** 统计量 $T(X)$ 是参数 θ 的**充分统计量**，如果给定 $T(X)$ 的值后，样本 X 的条件分布不再依赖于 θ ： $P(X = x \mid T(X) = t)$ 与 θ 无关
- **直觉：** 充分统计量"捕获"了样本中关于 θ 的全部信息，其余信息与参数无关。充分统计量**不唯一**。
- **比值准则：** 若对样本空间中每个 $\mathbf{x}$ ，比值 $\frac{p(\mathbf{x}|\theta)}{q(T(\mathbf{x})|\theta)}$ 关于 θ 为常数，则 $T(\mathbf{X})$ 是充分统计量。
- **因子分解定理：** $T(X)$ 是充分统计量**当且仅当**联合密度可以分解为： $f(\mathbf{X} \mid \theta) = g(T(\mathbf{X}), \theta) \cdot h(\mathbf{X})$ ，其中 $h(\mathbf{X})$ 是与 θ 无关的非负函数（直觉：纯噪声）， $g(T(\mathbf{X}), \theta)$ 仅通过 $T(\mathbf{X})$ 依赖于样本。

指数型分布族回顾

- **标准形式：**

$$f(x|\theta) = h(x) \cdot c(\theta) \cdot \exp\left(\sum_{i=1}^k \eta_i(\theta) T_i(x)\right)$$

其中：

- $h(x)$ ：与参数无关的基础函数
- $\eta(\theta)$ ：自然参数
- $T(x)$ ：充分统计量
- $c(\theta)$ ：归一化常数

- **充分统计量**：指数族的充分统计量直接由 $T(x)$ 给出。
- **常见分布对应关系**：

分布	自然参数	充分统计量
$N(\mu, \sigma^2)$	$(\mu/\sigma^2, -1/(2\sigma^2))$	$(\sum X_i, \sum X_i^2)$
$\text{Binominal}(n, p)$	$\log \frac{p}{1-p}$	$\sum X_i$
$\text{Poisson}(\lambda)$	$\log \lambda$	$\sum X_i$
$\text{Exponential}(\beta)$	$-1/\beta$	$\sum X_i$

最小充分统计量

- **定义**：充分统计量 $T(X)$ 称为**最小充分统计量**，若对任意其他充分统计量 $T'(X)$ ， $T(x)$ 都是 $T'(x)$ 的函数

最小充分统计量在所有充分统计量中实现**最大程度的数据压缩**，同时不丢失任何关于 θ 的信息。

- **Lehmann-Scheffé 判别定理**：若对任意两个样本点 x, y ，比值 $f(x|\theta)/f(y|\theta)$ 关于 θ 为常数 **当且仅当** $T(x) = T(y)$ ，则 $T(X)$ 是最小充分统计量。
- **非唯一性**：最小充分统计量的任意一一变换仍是最小充分统计量。

完备统计量

- **定义**：统计量 $T(X)$ 的分布族 $\{f(t|\theta)\}$ 称为**完备的**，若： $E_\theta[g(T)] = 0$ 对所有 θ 成立 $\implies P_\theta(g(T) = 0) = 1$ 对所有 θ 成立

唯一能让期望恒为零的函数 g ，就是**几乎处处为零的函数**。

完备则额外保证了**内部没有多余的结构**，所以完备充分 $\implies$ 最小充分，但反过来不成立。

辅助统计量

- **定义**：若统计量 $S(X)$ 的分布**不依赖于参数 θ** ，则称其为**辅助统计量**。
- **直觉**：辅助统计量单独不含关于 θ 的信息。
- **Basu 定理**：若 $T(X)$ 是**完备（最小）充分统计量**，则 $T(X)$ 与任意辅助统计量**相互独立**。

点估计

- **意义**：总体由 pdf/pmf $f(x|\theta)$ 描述，知道 θ 就知道整个总体。因此自然希望用样本构造 θ 的"好"估计。
- **定义**：点估计量是样本 $(X_1, \dots, X_n)$ 的任意函数 $W(X_1, \dots, X_n)$ ，即任意统计量都是点估计量。

| **注意**：定义中**不要求**估计量的值域与参数的值域一致（虽然理想情况下应一致）。

- **估计量 vs 估计值**：
 - **估计量**：随机变量 $W(X_1, \dots, X_n)$
 - **估计值**：将实际观测值代入后得到的具体数字 $W(x_1, \dots, x_n)$

估计方法

矩估计

- 基于样本矩等于总体矩的关系，构造参数估计量。
- 总体矩的定义： $\mu'_k = E[X^k]$, $m_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
- **步骤**：
 1. 参数或参数函数用总体矩表示。
 2. 用样本矩代替总体矩。
 3. 解方程组得到矩估计量。
- **缺点**：矩估计量一般不是充分统计量的函数（指数族除外），因此原则上可以通过条件化于充分统计量来改进（详见后文 Rao-Blackwell 定理）。

极大似然估计 (MLE)

- 寻找使"观测到当前样本的概率最大"的参数值。
- **步骤**：
 1. 写出似然函数 $L(\theta | x) = f(X_1, X_2, \dots, X_n | \theta)$ 。
 2. 取对数得到对数似然函数 $\ell(\theta) = \ln L(\theta)$ 。

3. 求解 $\frac{\partial \ell(\theta)}{\partial \theta} = 0$ ，得到极大似然估计值 $\hat{\theta}$ （检查参数空间边界：若极大值在边界取得，导数条件不适用）。
 4. 验证为极大值点： $\frac{\partial^2 \ell(\theta)}{\partial \theta^2} < 0$ 。
- **特点**：大样本下具有一致性和有效性。
 - **不变性定理**：若 $\hat{\theta}$ 是 θ 的 MLE，则对任意函数 $\tau(\theta)$ ， $\tau(\hat{\theta})$ 是 $\tau(\theta)$ 的 MLE。

贝叶斯估计 (Bayes)

- 综合先验信息和样本数据，通过后验分布进行估计。
- **步骤**：
 1. 给定先验分布 $\pi(\theta)$ 。
 2. 利用贝叶斯公式计算后验分布：

$$\pi(\theta|X) = \frac{f(x|\theta)\pi(\theta)}{P(X)}, P(X) = \int f(x|\theta)\pi(\theta)d\theta.$$
 3. 通过后验分布的期望或其他准则得到估计值。
- **特点**：适用于小样本，先验分布的选择影响估计结果。
- **共轭先验**：若先验 $\pi(\theta)$ 与后验 $\pi(\theta|\mathbf{x})$ 属于同一分布族，则称该族为**共轭族**，好处是后验有解析表达式，计算方便。

似然	共轭先验	后验
$\text{Bin}(n, p)$	$\text{Beta}(\alpha, \beta)$	$\text{Beta}(y + \alpha, n - y + \beta)$
$N(\theta, \sigma^2)$	$N(\mu, \tau^2)$	正态（均值、方差更新）
$\text{Poisson}(\lambda)$	$\text{Gamma}(\alpha, \beta)$	Gamma

评估点估计

均方误差 (MSE) 与无偏类的动机

- **均方误差 (MSE)** 是衡量估计量好坏的综合指标：

$$\text{MSE}_\theta(W) = E_\theta(W - \theta)^2 = \underbrace{\text{Var}_\theta(W)}_{\text{方差 (精度)}} + \underbrace{[\text{Bias}_\theta(W)]^2}_{\text{偏差}^2 \text{ (准确度)}}$$

其中**偏差**定义为 $\text{Bias}_\theta(W) = E_\theta(W) - \theta$ 。

- 对全体估计量，不存在对所有 θ 同时最小化 MSE 的估计量。例如常数估计量 $\hat{\theta} \equiv c$ 在 $\theta = c$ 处 MSE 为 0，但其他地方很差。因此限制到**无偏估计类**，此时 $\text{MSE} = \text{Var}$ ，问题转化为**最小化方差**。

偏差-方差权衡：有时有偏估计量的 MSE 反而更小。例如 $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 有偏，但 MSE 小于无偏的 S^2 。这说明"无偏"不等于"好"，只是一种常用的限制条件。

一致最小方差无偏估计 (UMVUE)

- 定义**：若无偏估计量 W^* 满足对所有 θ ， $\text{Var}_\theta(W^*) \leq \text{Var}_\theta(W)$ 对一切无偏估计量 W 成立，则称 W^* 为**一致最小方差无偏估计量 (UMVUE)**。

方法一：Cramér-Rao 下界

- 核心思路**：给出无偏估计量方差**的理论下界**。若某无偏估计量的方差恰好等于下界，则它就是 UMVUE。
- 前提**：(正则条件) 可以在积分号下对 θ 求导， $\frac{d}{d\theta} E_\theta[W(X)] = \int \frac{\partial}{\partial \theta} [W(x)f(x|\theta)] dx$

若 pdf 的支撑依赖于参数 (如 $U(0, \theta)$)，正则条件**不满足**，定理不可用。

- 定理**：设 $W(\mathbf{X})$ 是 $\tau(\theta)$ 的无偏估计量，则 $\text{Var}_\theta(W) \geq \frac{[\tau'(\theta)]^2}{I_n(\theta)}$

其中 **Fisher 信息量**为： $I_n(\theta) = E_\theta \left[\left(\frac{\partial}{\partial \theta} \log f(\mathbf{X}|\theta) \right)^2 \right] = -E_\theta \left[\frac{\partial^2}{\partial \theta^2} \log f(\mathbf{X}|\theta) \right]$

iid 情形： $I_n(\theta) = n \cdot I_1(\theta)$ ，只需计算单个观测的 Fisher 信息量。

- 使用方式**：计算下界后，若已知某无偏估计量方差恰好等于下界，则它是 UMVUE。若无估计量达到下界，**不能断定** UMVUE 不存在，需换方法。

局限性：下界不一定可达。例如正态总体 μ 未知时估计 σ^2 ， S^2 的方差大于 C-R 下界，但 S^2 仍是 UMVUE。

方法二：Rao-Blackwell + Lehmann-Scheffé 定理

- Rao-Blackwell 定理** (缩小搜索范围)

设 W 是 $\tau(\theta)$ 的任意无偏估计量, T 是充分统计量, 令 $\phi(T) = E(W|T)$, 则 $\phi(T)$ 是比 W 更优 (或相当) 的无偏估计量

- **Lehmann-Scheffé 定理** (保证唯一最优)

Rao-Blackwell 缩小了范围, 但仍可能有多个基于充分统计量的无偏估计量。完备性封堵了这种可能性: 若 T 是完备充分统计量, $\phi(T)$ 是基于 T 的无偏估计量, 则 $\phi(T)$ 是唯一的 UMVUE。

- **实用步骤:**

1. 找完备充分统计量 T
2. 构造任意一个 $\tau(\theta)$ 的无偏估计量 $h(X_1, \dots, X_n)$
3. 计算 $\phi(T) = E[h | T]$, 即为 UMVUE

两种方法的比较

	C-R 下界	Rao-Blackwell + 完备充分
适用条件	正则条件满足	能找到完备充分统计量
均匀分布	不适用	适用
下界不可达时	无法判断	仍可找到 UMVUE
典型用途	验证已有估计量是否最优	构造 UMVUE

假设检验

基本概念

原假设/对立假设

- **统计假设**是关于总体参数 θ 的陈述。假设检验的目标是: 基于样本数据, 在两个互补假设之间做出判断。

假设	符号	含义
原假设	$H_0 : \theta \in \Theta_0$	默认成立的假设, 通常表示"无效果/无差异"
备择假设	$H_1 : \theta \in \Theta_0^c$	希望验证的假设, 通常表示"有效果/有差异"

检验统计量与拒绝域

- 检验统计量 $W(X_1, \dots, X_n)$ ：从样本计算出的数值，用于做出接受/拒绝决策
- 拒绝域（临界域） R ：使得 H_0 被拒绝的样本值集合
- 接受域：拒绝域的补集

观测到 $x \in R \Rightarrow$ 拒绝 H_0 $x \notin R \Rightarrow$ 接受 H_0

检验统计量

似然比检验

- 核心思想：比较"限制在 H_0 下"与"不加限制"时，数据出现的最大可能性之比。
- 基于最大化似然函数，比较两种假设下的似然值。计算似然比并与临界值比较。
- 统计量： $\lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta|x)}{\sup_{\theta \in \Theta} L(\theta|x)}$, $0 \leq \lambda(x) \leq 1$ 。
- $\lambda(x)$ 越小，说明 H_1 下数据出现的可能性远大于 H_0 ，应拒绝 H_0 。
- 拒绝域： $R : \{x : \lambda(x) \leq c\}$ ，其中 c 由显著性水平 α 确定。
- 拒绝域仅通过充分统计量依赖于样本， $\lambda(x) = \lambda^*(T(x))$ 。

贝叶斯检验

- 核心思想：利用贝叶斯定理，将先验信息与样本信息结合，计算 H_0 、 H_1 的后验概率， $\pi(\theta|x) \propto f(x|\theta) \cdot \pi(\theta)$ ，据此决策。
- 决策规则：接受 $H_0 \iff P(\theta \in \Theta_0|X) \geq P(\theta \in \Theta_1|X)$
即后验概率更大的假设被接受。若需更严格控制错误拒绝，可设更高阈值（如 $P(\theta \in \Theta_1|X) > 0.99$ ）。

与经典方法的区别：经典统计学将 θ 视为固定未知值，不讨论 θ 的概率；贝叶斯方法将 θ 视为随机变量，可直接计算假设为真的概率。

评估假设检验

两类错误

无论做出哪种决策，都可能犯错：

- **第一类错误 (Type I)：** H_0 为真时错误拒绝，概率记为 α (显著性水平)
- **第二类错误 (Type II)：** H_1 为真时错误接受，概率记为 β

	H_0 为真	H_1 为真
接受 H_0	正确	第二类错误
拒绝 H_0	第一类错误	正确

关键矛盾：在样本量固定时，减小 α 会导致 β 增大，两者无法同时任意缩小。
因此统计学的惯例是：**优先控制第一类错误**，在此约束下再尽量减小第二类错误。

功效函数

- 功效函数表示在不同参数值下，检验拒绝原假设的概率。
- **功效函数**统一描述了检验犯错的概率： $\beta(\theta) = P_\theta(X \in R)$
- 其含义随 θ 所在区域而变化：
$$\beta(\theta) = \begin{cases} \text{第一类错误概率} & \theta \in \Theta_0 \\ 1 - \text{第二类错误概率} & \theta \in \Theta_1 \end{cases}$$
- **理想的功效函数：**在 Θ_0 上接近 0，在 Θ_1 上接近 1。

Size 与 Level

为了控制第一类错误，引入以下概念：

- **大小为 α 的检验 (Size α)：** $\sup_{\theta \in \Theta_0} \beta(\theta) = \alpha$
- **水平为 α 的检验 (Level α)：** $\sup_{\theta \in \Theta_0} \beta(\theta) \leq \alpha$

一致最优检验 (UMP)

- **定义：**在所有水平 α 检验中，功效函数对每个 $\theta \in \Theta_1$ 均最大的检验， $\beta(\theta) \geq \beta'(\theta)$ ， $\forall \theta \in \Theta_1$ ，对所有其他水平 α 检验的功效函数 $\beta'(\theta)$ 成立。

直觉上：UMP 检验是"在控制第一类错误的前提下，第二类错误最小的检验"。

- **构造方法：**
 - **简单假设下**，使用Neyman-Pearson引理

- **适用场景**：适用于 $H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$
- **步骤**：
 1. 写出每个样本点的似然比 $\lambda(x) = \frac{f(x|\theta_0)}{f(x|\theta_1)}$
 2. 找到拒绝域 $\{\lambda(x) < k\}$ ，调整 k 使得第一类错误概率恰好等于 α
 3. 在给定显著性水平下，检验具有最大功效

◦ **单边假设下，使用Karlin-Rubin方法**

- **适用场景**：适用于如 $H_0 : \theta \leq \theta_0$ vs $H_1 : \theta > \theta_0$
- **前提条件**：充分统计量 $T(X)$ 的分布族具有**单调似然比性质**（定义：对任意 $\theta_2 > \theta_1$ ， $\frac{f(x|\theta_2)}{f(x|\theta_1)}$ 是 x 的单调不减函数）
- **步骤**：
 1. 找到证明统计量 $T(X)$ 关于参数 θ 有单调似然比
 2. 拒绝域通常为 $T(X) > c$ 的形式
 3. 由 $P_{\theta_0}(T > c) = \alpha$ 选取合适的临界值 c

◦ **UMP 检验不存在的情形**

对于**双侧假设** $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$ ，UMP 检验通常**不存在**。

直觉上：无偏检验保证"当备择假设为真时，拒绝原假设的概率"不低于"当原假设为真时，拒绝原假设的概率"，是一个合理的最低要求。

p 值

- **定义**： p 值 = 在 H_0 成立的前提下，观测到当前结果或更极端结果的概率

若检验统计量 $W(X)$ 取值越大越支持 H_1 ，则 $p(x) = \sup_{\theta \in \Theta_0} P_{\theta}(W(X) \geq W(x))$

部分	含义
$W(x)$	你实际观测到的统计量的值
$W(X) \geq W(x)$	"比现在更极端"的事件
$P_{\theta}(\cdot)$	在 H_0 某个参数值下计算概率

部分	含义
$\sup_{\theta \in \Theta_0}$	取 H_0 下最不利的参数值（保证控制第一类错误）

简单假设 ($H_0: \theta = \theta_0$) 时, $\sup$ 直接去掉: $p(x) = P_{\theta_0}(W(X) \geq W(x))$

- **决策**: $p(x) \leq \alpha \implies$ 拒绝 H_0

当 H_0 为真时, p 值落在 $[0, \alpha]$ 的概率本身就不超过 α , 所以用 $p(x) \leq \alpha$ 作为拒绝域, 第一类错误自动被控制住。

决策理论：损失函数

之前评价检验只看"犯错概率", 但现实中**不同错误的代价不同**:

- 误判无辜为有罪（第一类错误）vs 放走真正罪犯（第二类错误）
- 误判新药无效（第一类错误）vs 推广实际无效的药（第二类错误）

损失函数就是把这种**代价差异**数学化。

0-1 损失的推广

$$L(\theta, a_0) = \begin{cases} 0 & \theta \in \Theta_0 \\ c_{II} & \theta \in \Theta_1 \end{cases} \quad L(\theta, a_1) = \begin{cases} c_I & \theta \in \Theta_0 \\ 0 & \theta \in \Theta_1 \end{cases}$$

- 用表格更直观:

	$\theta \in \Theta_0$ (H_0 为真)	$\theta \in \Theta_1$ (H_1 为真)
接受 H_0 (a_0)	损失 0	损失 c_{II}
拒绝 H_0 (a_1)	损失 c_I	损失 0

普通 0-1 损失是特例: 令 $c_I = c_{II} = 1$ 即可。

风险函数

- 对损失取期望, 得到风险函数:

$$R(\theta, \delta) = \begin{cases} c_I \cdot \beta(\theta) & \theta \in \Theta_0 \\ c_{II} \cdot (1 - \beta(\theta)) & \theta \in \Theta_1 \end{cases}$$

- **推导过程** (以 $\theta \in \Theta_0$ 为例):

$$R(\theta, \delta) = E_{\theta}[L(\theta, \delta(X))] = c_I \cdot P_{\theta}(\text{拒绝 } H_0) + 0 \cdot P_{\theta}(\text{接受 } H_0) = c_I \cdot \beta(\theta)$$

风险函数的意义

$$\underbrace{R(\theta, \delta)}_{\text{总风险}} = \underbrace{c_I}_{\text{犯错代价}} \times \underbrace{\beta(\theta)}_{\text{犯错概率}}$$

• 两个旋钮：

- 想降低风险，可以降低 $\beta(\theta)$ （改进检验）
- 也可以重新审视 c_I, c_{II} 的设定（重新定义问题）

• 与之前方法的联系：

方法	本质
Size α 检验	约束 c_I 方向的风险上界
UMP 检验	在约束 c_I 下最小化 c_{II} 方向的风险
损失函数方法	同时权衡两个方向，由 c_I/c_{II} 的比值决定侧重

区间估计

核心思想：点估计给出参数的"最佳猜测"，但正确概率为 0。
区间估计牺牲精度，换取对参数的**覆盖保证**。

基本概念

- **区间估计量：**一对函数 $L(X), U(X)$ ，满足 $L(x) \leq U(x)$ ，推断为 $L(x) \leq \theta \leq U(x)$ 。
- **覆盖概率：** $P_{\theta}(\theta \in [L(X), U(X)])$ ，随 θ 变化。
- **置信系数：** $\inf_{\theta} P_{\theta}(\theta \in [L(X), U(X)])$ ，即最坏情况下的覆盖概率。

关键认知：随机量是**区间**，不是参数。

"95% 置信区间"的含义是：在重复抽样中，**95% 的区间**会覆盖真实参数，而不是"参数有 95% 的概率落在某个固定区间内"。

区间获得方法

检验反演法

- 核心对应关系：接受域 $\longleftrightarrow$ 置信集

检验视角	区间估计视角
固定参数 θ_0 ，看样本 x 是否支持它	固定样本 x ，问哪些参数被样本支持
接受域 $A(\theta_0) \subset \mathcal{X}$	置信集 $C(x) \subset \Theta$

- 构造步骤：
 - 对每个 θ_0 ，构造水平 α 检验 $H_0 : \theta = \theta_0$ 的接受域 $A(\theta_0)$
 - 定义置信集： $C(x) = \{\theta_0 : x \in A(\theta_0)\}$
 $\{\theta_0 \in C(x)\} \iff \{x \in A(\theta_0)\}$
 - 结论： $C(X)$ 是 $1 - \alpha$ 置信集

实用价值：构造接受域比直接构造置信集容易得多。
所有构造检验的方法（LRT、UMP等）都可以直接用来构造置信集。

枢轴量法

- 定义：随机变量 $Q(X, \theta)$ 称为**枢轴量 (Pivot)**，若其分布与 θ 完全无关。
- 构造步骤：
 - 找到枢轴量 $Q(X, \theta)$
 - 找常数 a, b （与参数无关），使得： $P(a \leq Q(X, \theta) \leq b) = 1 - \alpha$
 - 对不等式反解 θ ，得到置信区间 $C(x)$

若 $Q(x, \theta)$ 关于 θ 单调，则反解后一定是区间形式。

- 常用枢轴量速查表：

场景	枢轴量	分布
正态均值， σ^2 已知	$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0, 1)$

场景	枢轴量	分布
正态均值, σ^2 未知	$\frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$
正态方差	$\frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$
指数分布均值 λ	$\frac{2 \sum X_i}{\lambda}$	$\chi^2(2n)$

CDF 枢轴法

- **适用场景**：找不到显式枢轴量时，尤其适合**离散分布**。
- **核心思路**：直接利用统计量 T 的 CDF 来确定置信区间端点。

对观测值 $T = t$ ，求解使下式成立的 θ_L, θ_U ：

$$P_{\theta_U}(T \leq t) = \frac{\alpha}{2}, \quad P_{\theta_L}(T \geq t) = \frac{\alpha}{2}$$

则 $[\theta_L, \theta_U]$ 是 $1 - \alpha$ 置信区间。

离散分布时，由于概率不连续，只能保证覆盖概率 $\geq 1 - \alpha$ 。

贝叶斯可信集

- **与置信区间的本质区别**：

	置信区间	贝叶斯可信集
θ 的性质	固定未知值	随机变量
概率来源	重复抽样	后验分布
表述	95% 的区间覆盖真值	θ 有 95% 概率落在区间内

- **构造方法**：给定后验分布 $\pi(\theta|x)$ ，找集合 C 使得： $\int_C \pi(\theta|x) d\theta = 1 - \alpha$
- **最高后验密度区间 (HPD)**：在所有满足覆盖概率的区间中长度最短的那个

$$C_{\text{HPD}} = \{\theta : \pi(\theta|x) \geq k\}$$

其中 k 由 $\int_{C_{\text{HPD}}} \pi(\theta|x) d\theta = 1 - \alpha$ 确定。

后验单峰时，HPD 就是"后验密度最高的那段区域"，是最短的可信区间。

区间估计评价

两个相互制约的目标：区间越短越好，覆盖概率越高越好。

准则一：最短区间

- **核心结论**：若枢轴量的密度 f 是**单峰的**，最短 $1 - \alpha$ 区间 $[a, b]$ 满足： $f(a) = f(b)$ 且 $\int_a^b f(x) dx = 1 - \alpha$
- **推论**：
 - 对称单峰分布（如正态、 t ）→ 等尾分割 $\alpha_1 = \alpha_2 = \alpha/2$ **最优**
 - 偏斜分布（如 χ^2 ）→ 等尾分割**不是最优**，但实践中仍常用

准则二：UMA（一致最精确置信集）

- **错误覆盖概率**：当真实参数为 θ 时，区间却覆盖了错误值 θ' 的概率 $P_\theta(\theta' \in C(X)), \theta' \neq \theta$
- **定义**：在所有 $1 - \alpha$ 置信集中，对每个错误值都使错误覆盖概率最小的，称为 **UMA 置信集**。
- **构造方法**：反转 UMP 检验的接受域。
- **局限性**：UMA 置信集只在**单边情形下存在**，双侧情形通常不存在。