

概率论基础

☼ Checkbox	学会有笔记
🕒 level	本科
🕒 分支	概率统计

推荐教材

Introduction to Probability,

Dimitri P. Bertsekas and John N. Tsitsiklis (chapter1-5)

样本空间和概率

集合论基础

- **集合**：不同对象的集合，被视为一个独立的对象。
- **事件**：样本空间的一个子集，代表一个或多个可能的结果。
- **集合运算**：
 - 补集 S^c
 - 并集 **union** $S \cup T$
 - 交集 **intersection** $S \cap T$
 - De Morgan 定律 $(\bigcup_n S_n)^c = \bigcap_n S_n^c$

概率模型

- **样本空间 (Sample Space)**：实验所有可能结果的集合。
- **概率函数 (P)**：将事件映射到 $[0, 1]$ 区间的函数，需满足以下三大概率公理。"有利结果/总结果"仅是**离散均匀分布**下的特例。
- **概率公理**：

- 非负性： $P(A) \geq 0$
- 可加性： $A \cap B = \emptyset$, 则 $P(A \cup B) = P(A) + P(B)$
- 归一性： $P(\Omega) = 1$
- **可推导性质：**
 - $P(\emptyset) = 0$
 - $P(A^c) = 1 - P(A)$
 - $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- **类型：**
 - 离散概率模型：适用于有限或可数无限样本空间。
 - **等可能情况下计算概率：**
 - 对于单个结果： $P(\text{单个结果}) = \frac{1}{\text{总结果数量}}$
 - 对于有多个结果的事件： $P(\text{事件}) = \frac{\text{有利结果数量}}{\text{总结果数量}}$
 - 连续概率模型：适用于样本空间是无限且不可数的情况，例如测量结果。

条件概率

- **定义：**条件概率是在另一个事件发生的条件下，某一事件发生的概率。
- **公式：**如果事件 A 和事件 B 都是样本空间 S 的事件，且 $P(B) > 0$ ，则事件 B 发生条件下事件 A 发生的概率定义为：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$
- **解读：**条件概率可以被理解为事件 B 已经发生的情况下，事件 A 发生的概率。
- **乘法规则：** $P(A_1 \cap A_2 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2 | A_1) \cdots P(A_n | A_1 \cap \cdots \cap A_{n-1})$

全概率公式

- **定义：**总概率公式是将一个事件的概率表示为该事件在其他一系列互斥且完全穷尽的事件下的条件下的概率之和。

- **公式：**如果事件 $B_1, B_2, \dots, B_n$ 构成样本空间 S 的一个划分，则对于 S 中的任何事件 A ：

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$

贝叶斯定理

- **定义：**贝叶斯定理提供了一种在已知其他相关事件的概率的情况下，计算某一事件发生概率的方法。
- **公式：**如果事件 $B_1, B_2, \dots, B_n$ 构成样本空间的一个划分，则对于 S 中的任何事件 A ，且 $P(A) > 0$ ：

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)}$$
 其中， $P(A)$ 可以通过总概率公式计算。

独立性

- **两事件独立性定义：**如果一个事件的发生不影响另一个事件发生的概率，则这两个事件被称为独立事件。
 - 两个事件 A 和 B 是独立的，当且仅当：

$$P(A \cap B) = P(A)P(B)$$
 - 事件 A 和 B 的独立性意味着：

$$P(A|B) = P(A) \quad \text{和} \quad P(B|A) = P(B)$$
 - **性质：**独立性是相互的，如果 A 和 B 是独立的，那么 B 和 A 也是独立的，且 A 和 B^c 也是独立的。

- **多事件独立性**需要对**所有子集**满足乘积公式，而不仅仅是两两独立：

$$P\left(\bigcap_{i \in S} A_i\right) = \prod_{i \in S} P(A_i), \quad \forall S \subseteq \{1, 2, \dots, n\}$$

| **两两独立 $\neq$ 相互独立。**

- **条件独立性完全缺失：**

$$P(A \cap B | C) = P(A | C) \cdot P(B | C)$$

| **独立性与条件独立性互不蕴含**

计数的基本原理

- **加法原理**：如果一个事件可以分成几个互不相交的子事件，那么这个事件的总可能性就是这些子事件可能性的总和。
- **乘法原理**：如果一个事件可以分为若干个连续的步骤，那么这个事件的总可能性就是这些步骤可能性的乘积。
- **排列与组合**：排列考虑元素的顺序，而组合不考虑顺序。

排列

- **定义**：排列是将 n 个不同元素按照一定顺序排列起来。
- **公式**：

- 从 n 个元素中取出 r 个元素进行排列：

$$P(n, r) = \frac{n!}{(n-r)!}$$

- n 个元素的全排列：

$$P(n) = n!$$

组合

- **定义**：组合是从 n 个不同元素中选取 r 个元素，不考虑顺序。
- **公式**：

- 从 n 个元素中取出 r 个元素进行组合：

$$C(n, r) = \frac{n!}{r!(n-r)!}$$

- 组合数的对称性质：

$$C(n, r) = C(n, n - r)$$

分区

- **定义**：分区是指将 n 个元素分成 r 组，第 i 组有 n_i 个元素。
- **公式**： $\binom{n}{n_1, n_2, \dots, n_r} = \frac{n!}{n_1! n_2! \dots n_r!}$ ，其中 $n_1 + n_2 + \dots + n_r = n$ 。
- **性质**：分区与组合和排列不同，它不要求元素之间有顺序关系。

离散随机变量

- **随机变量**是实验结果的实值函数。
- **离散随机变量**的取值为有限个或可数无限个。

概率质量函数 (PMF)

- **定义**：描述离散随机变量取特定值的概率。
- **表示**：对于随机变量 X ，其概率质量函数表示为 $p_X(x) = P(X = x)$ ，其中 $\sum_x p_X(x) = 1$ 。
- **计算方法**：对每个可能值 x ，收集所有导致 $X = x$ 的结果，累加其概率即得 $p_X(x)$ 。

随机变量的函数

- **定义**：通过函数变换，从已有的随机变量得到新的随机变量。若 $Y = g(X)$ ，则 Y 也是随机变量，其 PMF 为： $p_Y(y) = \sum_{\{x|g(x)=y\}} p_X(x)$
- 随机变量的**函数**仍是一个随机变量，其 PMF 可从原随机变量的 PMF 推导得出。

期望和方差

- **期望 (Expectation)**： $E[X] = \sum_x x \cdot P(X = x)$
 - **期望值规则 (Expected Value Rule)**：计算 $g(X)$ 的期望，无需先求 $g(X)$ 的 PMF： $E[g(X)] = \sum_x g(x) p_X(x)$

| 一般情况下 $E[g(X)] \neq g(E[X])$ ，仅当 g 为线性函数时等号成立。
 - **线性变换性质**：若 $Y = aX + b$ ，则： $E[aX + b] = aE[X] + b$ ，
 $\text{Var}(aX + b) = a^2 \text{Var}(X)$
- **方差 (Variance)**： $\text{Var}(X) = E[(X - E(X))^2] = E[X^2] - (E[X])^2$
- **标准差 (Standard Deviation)**： $\sigma_X = \sqrt{\text{var}(X)}$

常见离散随机变量分布和期望方差

1. 伯努利分布 (Bernoulli)

- 描述单次伯努利试验成功的概率。
- 概率质量函数： $P(X = 1) = p, \quad P(X = 0) = 1 - p$
- 期望： $E[X] = p$
- 方差： $\text{Var}(X) = p(1 - p)$
- 标准差： $\sigma_X = \sqrt{p(1 - p)}$

2. 二项分布 (Binomial)

- 描述n次独立的伯努利试验中成功k次的概率。
- 概率质量函数： $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$
- 期望： $E[X] = np$
- 方差： $\text{Var}(X) = np(1 - p)$
- 标准差： $\sigma_X = \sqrt{np(1 - p)}$

3. 几何分布 (Geometric)

- 描述在一系列独立的伯努利试验中，获得第一次成功所需的试验次数。
- 概率质量函数： $P(X = k) = (1 - p)^{k-1} p$
- 期望： $E[X] = \frac{1}{p}$
- 方差： $\text{Var}(X) = \frac{1 - p}{p^2}$
- 标准差： $\sigma_X = \frac{\sqrt{1 - p}}{p}$

4. 泊松分布 (Poisson)

- 描述在固定时间或空间间隔内，某事件发生的次数。
- 概率质量函数： $P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$
- 期望： $E[X] = \lambda$
- 方差： $\text{Var}(X) = \lambda$
- 标准差： $\sigma_X = \sqrt{\lambda}$

联合概率质量函数、条件概率和独立性

联合 PMF

- 定义：同时描述两个随机变量取值的概率 $p_{X,Y}(x, y) = P(X = x, Y = y)$
- 从联合 PMF 还原各自的 PMF (边缘 PMF) : $p_X(x) = \sum_y p_{X,Y}(x, y), \quad p_Y(y) = \sum_x p_{X,Y}(x, y)$
- 期望的计算与线性性：
 - $E[g(X, Y)] = \sum_x \sum_y g(x, y) p_{X,Y}(x, y)$
 - $E[aX + bY + c] = aE[X] + bE[Y] + c$ (不需要独立性)

条件 PMF 与条件期望

- 核心思想：已知某事件发生后，在新的样本空间中重新描述概率分布
- 定义：
 - $p_{X|A}(x) = P(X = x | A) \quad p_{X|Y}(x | y) = \frac{p_{X,Y}(x, y)}{p_Y(y)}$
 - $E[X | A] = \sum_x x p_{X|A}(x) \quad E[X | Y = y] = \sum_x x p_{X|Y}(x | y)$
- 条件 PMF $\rightarrow$ 联合/边缘 PMF :
 - $p_{X,Y}(x, y) = \underbrace{p_Y(y) p_{X|Y}(x | y)}_{\text{乘法规则}}$
 - $p_X(x) = \underbrace{\sum_y p_Y(y) p_{X|Y}(x | y)}_{\text{全概率公式}}$
- 全期望定理：
 - $E[X] = \sum_i P(A_i) E[X | A_i] = \sum_y p_Y(y) E[X | Y = y]$

独立性

- 定义：Y 的取值不提供任何关于 X 的信息
 - $X \perp Y \iff p_{X,Y}(x, y) = p_X(x) p_Y(y) \iff p_{X|Y}(x | y) = p_X(x)$
- 独立性的推论：

性质	公式	是否需要独立
期望线性性	$E[X + Y] = E[X] + E[Y]$	✗
期望乘积	$E[XY] = E[X]E[Y]$	✓
方差可加性	$\text{var}(X + Y) = \text{var}(X) + \text{var}(Y)$	✓
函数独立性	$E[g(X)h(Y)] = E[g(X)]E[h(Y)]$	✓

一般随机变量

- **定义**：可以在某个区间或多个区间内取任意值的随机变量。
- **特点**：概率分布由概率密度函数（PDF）描述，而非概率质量函数（PMF）。

概率密度函数（PDF）

- **定义**：描述连续随机变量取值的概率分布； $f_X(x)$ 本身并不表示概率，它表示的是随机变量 X 取值在某个点附近的概率密度。
- **性质**：概率密度函数在整个取值范围内的积分等于1。
 1. 非负性：对于所有的 x ，有 $f_X(x) \geq 0$ 。
 2. 归一化：PDF在整个实数域上的积分等于1，即 $\int_{-\infty}^{\infty} f_X(x) dx = 1$ 。
 3. 小区间近似：如果 δ 是一个非常小的数，则随机变量 X 落在区间 $[x, x + \delta]$ 内的概率约于 $f_X(x) \cdot \delta$ 。
 4. 单点概率为零：随机变量 X 落在某个特定点 x 的概率实际上是0。
 5. 任意子集概率：对于实数线上的任意子集 B ， $P(X \in B) = \int_B f_X(x) dx$ 。
- **期望 (Expectation)**：连续随机变量的平均值，可理解为 PDF 图像的重心。

$$E[X] = \int_{-\infty}^{\infty} x f_X(x) dx$$

$$E[g(X)] = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

$$E[X^n] = \int_{-\infty}^{\infty} x^n f_X(x) dx, \text{ n阶矩 (n-th moment)}$$

$$\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty \text{ 是期望有限且明确定义的条件。}$$
- **方差 (Variance)**：

$$\text{Var}(X) = E[(X - E[X])^2] = \int_{-\infty}^{\infty} (x - E[X])^2 f_X(x) dx = E[X^2] - (E[X])^2.$$

- 线性变换 ($Y = aX + b$) :
 $E[Y] = aE[X] + b, \text{Var}(Y) = a^2\text{Var}(X).$

累积分布函数 (CDF)

- 定义： $F_X(x) = P(X \leq x)$ ，并且具有以下性质：
 1. 非减性。
 2. 极限性质：
 - 当 x 趋向负无穷时， $F_X(x)$ 趋向于0。
 - 当 x 趋向正无穷时， $F_X(x)$ 趋向于1。
 3. 随机变量的CDF：
 - 如果 X 是离散的，则 $F_X(x)$ 在 X 的取值点上是跳跃的。
 - 如果 X 是连续的，则 $F_X(x) = \int_{-\infty}^x f_X(t) dt$ ， $F_X(x)$ 是关于 x 的连续函数。
 4. 离散随机变量的PMF与CDF的关系：
 - $p_X(k) = P(X \leq k) - P(X \leq k - 1) = F_X(k) - F_X(k - 1)$
 - $F_X(k) = \sum_{i=-\infty}^k p_X(i)$
 5. 连续随机变量的PDF与CDF的关系：
 - $f_X(x) = \frac{d}{dx} F_X(x)$
 - $F_X(x) = \int_{-\infty}^x f_X(t) dt$

实用技巧：当直接求PMF/PDF困难时，可先求CDF，再通过差分（离散）或求导（连续）得到PMF/PDF。

常见连续随机变量分布

1. 均匀分布 (Uniform)

- 描述在某个区间内等概率取值的随机变量。
- 概率密度函数：
$$f(x) = \begin{cases} \frac{1}{b-a} & \text{for } a \leq x \leq b \\ 0 & \text{otherwise} \end{cases}$$

- $E[X] = \frac{a+b}{2}, Var(X) = \frac{(b-a)^2}{12}$
- CDF: $F_X(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$

2. 指数分布 (Exponential)

- 描述泊松过程中事件之间的时间间隔。
- 概率密度函数: $f(x) = \lambda e^{-\lambda x}$ for $x \geq 0$
- $E[X] = \frac{1}{\lambda}, Var(X) = \frac{1}{\lambda^2}$
- CDF: $F_X(x) = 1 - e^{-\lambda x}, x \geq 0$
- **无记忆性 (Memoryless Property)**: 已知事件尚未发生, 剩余等待时间的分布与原来完全相同

$$P(X > x \mid X > t) = \frac{P(X > t+x)}{P(X > t)} = \frac{e^{-\lambda(t+x)}}{e^{-\lambda t}} = e^{-\lambda x}$$

$$P(T > t+x \mid T > t) = P(T > x)$$

3. 正态分布 (Normal)

- 描述许多自然和社会现象中的随机变量。
- 概率密度函数: $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$
- 参数: μ (均值), σ^2 (方差), 记作 $X \sim N(\mu, \sigma^2)$
- **线性变换保持正态性**: 若 $X \sim N(\mu, \sigma^2)$, $a \neq 0$, 则 $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$
- **标准正态分布**: 均值为 0、方差为 1 的正态分布, 记 $Y \sim N(0, 1)$, 其 CDF 记为 $\Phi(y) = P(Y \leq y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt$
- **对称性**: $\Phi(-y) = 1 - \Phi(y)$ (用于查负值)
- **标准化方法**: $P(X \leq x) = P\left(\frac{X-\mu}{\sigma} \leq \frac{x-\mu}{\sigma}\right) = \Phi\left(\frac{x-\mu}{\sigma}\right)$

联合概率密度函数

- **定义**：描述两个或多个连续随机变量共同分布的函数 $f_{X,Y}(x,y)$ ，满足：

$$f_{X,Y}(x,y) \geq 0, \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx dy = 1$$

几何含义： $f_{X,Y}(x,y) \cdot \delta^2 \approx P(x \leq X \leq x + \delta, y \leq Y \leq y + \delta)$ ，即单位面积上的概率密度。

- **概率的计算**：对平面上任意集合 B ， $P((X,Y) \in B) =$

$$\iint_{(x,y) \in B} f_{X,Y}(x,y) dx dy$$

特别地，对矩形区域： $P(a \leq X \leq b, c \leq Y \leq d) = \int_a^b \int_c^d f_{X,Y}(x,y) dy dx$

这是联合 PDF 最核心的用途：**所有概率计算都归结为对 $f_{X,Y}$ 在对应区域上的积分。**

- **边缘 PDF (Marginal PDF)**：从联合 PDF 还原单个变量的分布

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dx$$

- **联合 CDF (Joint CDF)**：

$$F_{X,Y}(x,y) = P(X \leq x, Y \leq y) = \int_{-\infty}^x \int_{-\infty}^y f_{X,Y}(s,t) dt ds$$

与联合 PDF 互推： $f_{X,Y}(x,y) = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}(x,y)$

- **期望值规则的推广**：

$$E[g(X,Y)] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x,y) f_{X,Y}(x,y) dx dy$$

$$E[aX + bY + c] = aE[X] + bE[Y] + c \quad (\text{线性情形})$$

以上结论可自然推广至 n 个随机变量。

条件概率和独立性

- **条件 PDF**

$$\text{给定事件 } A: f_{X|A}(x) = \begin{cases} \frac{f_X(x)}{P(X \in A)}, & x \in A \\ 0, & \text{otherwise} \end{cases}$$

形状不变，仅按 $\frac{1}{P(A)}$ 缩放以归一化。

$$\text{给定随机变量 } Y = y: f_{X|Y}(x | y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}, \quad f_Y(y) > 0$$

由此得**乘法规则**： $f_{X,Y}(x,y) = f_Y(y) \cdot f_{X|Y}(x|y)$

- 条件期望与全期望定理

$$E[X|A] = \int_{-\infty}^{\infty} x f_{X|A}(x) dx, \quad E[X|Y=y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx$$

全期望定理 (divide-and-conquer)：

- $E[X] = \sum_{i=1}^n P(A_i) E[X|A_i]$
- $E[X] = \int_{-\infty}^{\infty} E[X|Y=y] f_Y(y) dy$

- **独立性 (Independence)**

$$X \perp Y \iff f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y) \iff F_{X,Y}(x,y) = F_X(x) \cdot F_Y(y)$$

独立时的重要推论：

性质	公式
期望乘法	$E[XY] = E[X]E[Y]$
函数独立	$E[g(X)h(Y)] = E[g(X)] \cdot E[h(Y)]$
方差可加	$\text{Var}(X+Y) = \text{Var}(X) + \text{Var}(Y)$

连续贝叶斯规则

- 问题背景：已知未观测量 X 的先验分布 $f_X(x)$ ，以及在 $X = x$ 条件下观测量 Y 的条件分布 $f_{Y|X}(y|x)$ ，观测到 $Y = y$ 后，推断 X 的后验分布。

- 情形一 (X 和 Y 均为连续随机变量)：

$$f_{X|Y}(x|y) = \frac{f_X(x) f_{Y|X}(y|x)}{f_Y(y)} = \frac{f_X(x) f_{Y|X}(y|x)}{\int_{-\infty}^{\infty} f_X(t) f_{Y|X}(y|t) dt}$$

- 情形二 (X 为离散, Y 为连续 (混合情形))：

$$P(N=n|Y=y) = \frac{p_N(n) f_{Y|N}(y|n)}{\sum_i p_N(i) f_{Y|N}(y|i)}$$

- 记忆口诀

- 后验 $\propto$ 先验 $\times$ 似然
- 即： $f_{X|Y}(x|y) \propto f_X(x) \cdot f_{Y|X}(y|x)$ ，分母仅是归一化常数。

随机变量的进阶主题

派生分布

- 定义：派生分布是指通过已知分布的随机变量进行函数变换 $Y = g(X)$ 得到的新随机变量的分布。

- 核心方法：两步法

1. **第一步**：计算 Y 的 CDF $F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{\{x|g(x) \leq y\}} f_X(x) dx$

2. **第二步**：对 CDF 求导得到 PDF $f_Y(y) = \frac{dF_Y}{dy}(y)$

- 特殊情况

- 线性变换公式：若 $Y = aX + b$ ($a \neq 0$)，则 $f_Y(y) = \frac{1}{|a|} f_X\left(\frac{y-b}{a}\right)$

- 正态分布：若 $X \sim N(\mu, \sigma^2)$ ，则 $Y = aX + b \sim N(a\mu + b, a^2\sigma^2)$

- 严格单调函数公式：若 g 严格单调，存在反函数 h (即 $y = g(x) \Leftrightarrow x = h(y)$)，则 $f_Y(y) = f_X(h(y)) \cdot \left| \frac{dh}{dy}(y) \right|$

- 卷积公式（独立随机变量之和）：两个或多个独立随机变量相加得到一个新的随机变量

若 $Z = X + Y$ ， X 与 Y 独立，则 $f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx$ ， Z 也是一个随机变量。

性质：

Z 的期望是 X 和 Y 期望的和： $E(Z) = E(X) + E(Y)$ 。

Z 的方差是 X 和 Y 方差的和（如果 X 和 Y 是独立的）： $\text{Var}(Z) = \text{Var}(X) + \text{Var}(Y)$ 。

协方差与相关性

- 协方差 (Covariance)

衡量两个随机变量之间线性关系的方向与程度： $\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])] = E[XY] - E[X]E[Y]$

- 相关系数 (Correlation Coefficient)

标准化的协方差，度量线性关系的强度： $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$, $-1 \leq \rho \leq 1$

- 关键性质：

性质	说明
$\text{Cov}(X, Y) = 0$	称 X 与 Y 不相关
独立 $\Rightarrow$ 不相关	反之不成立 （不相关不代表独立）
$\rho = 1$ 或 -1	X 与 Y 存在严格线性关系

- 含协方差的方差公式（不要求独立）
 - 两变量： $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$
 - 多变量： $\text{Var}(\sum_{i=1}^n X_i) = \sum_{i=1}^n \text{Var}(X_i) + \sum_{\substack{i,j \\ i \neq j}} \text{Cov}(X_i, X_j)$

条件期望与条件方差

- 条件期望 $E[X | Y]$ 不是一个数，而是关于 Y 的**随机变量**：

- 当 $Y = y$ 时，它的取值为 $E[X | Y = y]$

- **迭代期望定律**： $E[E[X | Y]] = E[X]$

| **直觉**：先按 Y 的条件分组求期望，再对各组期望加权平均，结果等于总体期望。

- **全方差定律**： $\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$

项	含义
$E[\text{Var}(X Y)]$	组内方差的平均（平均不确定性）
$\text{Var}(E[X Y])$	组间均值的方差（均值的波动性）

- **条件期望作为估计量** $\hat{X} = E[X | Y]$ ，**估计误差** $\tilde{X} = X - \hat{X}$ ，则：
 - $E[\tilde{X}] = 0$ （无偏）
 - $\text{Cov}(\hat{X}, \tilde{X}) = 0$ （估计值与误差不相关）
 - $\text{Var}(X) = \text{Var}(\hat{X}) + \text{Var}(\tilde{X})$ （方差分解）

矩母函数

- 随机变量 X 的矩母函数 (MGF) 定义为： $M_X(s) = E[e^{sX}]$

- 核心性质

1. 求矩 (Moment Generation)

$$\left. \frac{d^n}{ds^n} M_X(s) \right|_{s=0} = E[X^n]$$

特别地： $M_X(0) = 1$, $M'_X(0) = E[X]$, $M''_X(0) = E[X^2]$

2. 线性变换

$$Y = aX + b \implies M_Y(s) = e^{sb} \cdot M_X(as)$$

3. 独立变量之和 (最重要)

$$X \perp Y \implies M_{X+Y}(s) = M_X(s) \cdot M_Y(s)$$

4. 唯一性

MGF 唯一确定一个分布。若两个随机变量的 MGF 相同，则分布相同。

- 常见分布的 MGF

分布	MGF
伯努利 Bernoulli(p)	$1 - p + pe^s$
二项 Binomial(n, p)	$(1 - p + pe^s)^n$
泊松 Poisson(λ)	$e^{\lambda(e^s - 1)}$
指数 Exp(λ)	$\frac{\lambda}{\lambda - s}, s < \lambda$
正态 $N(\mu, \sigma^2)$	$e^{\mu s + \sigma^2 s^2 / 2}$

随机个数独立随机变量之和

- 模型设定： $Y = X_1 + X_2 + \dots + X_N$

其中：

- N 是取非负整数值的随机变量
- $X_1, X_2, \dots$ 同分布，均值 $E[X]$ ，方差 $\text{Var}(X)$

- N 与所有 X_i **相互独立**
- 三个核心公式
 1. 期望 $E[Y] = E[N] \cdot E[X]$
 2. 方差 $\text{Var}(Y) = E[N] \text{Var}(X) + (E[X])^2 \text{Var}(N)$
 3. MGF $M_Y(s) = M_N(\log M_X(s))$
- | 操作方法：将 $M_N(s)$ 中每个 e^s 替换为 $M_X(s)$ 即可。

- 经典结论

情形	结论
几何个独立指数变量之和	仍为 指数分布 (参数 $p\lambda$)
几何个独立几何变量之和	仍为 几何分布 (参数 pq)
泊松个独立伯努利变量之和	仍为 泊松分布

独立随机变量的极限定理

不等式

马尔可夫不等式

- 定义：马尔可夫不等式提供了**非负随机变量**大于等于某个正数的概率的上界。
- 公式：对于非负随机变量 X 和任意正数 a ， $P(X \geq a) \leq \frac{E[X]}{a}$

切比雪夫不等式

- 定义：切比雪夫不等式给出了**随机变量**（无非负要求）偏离其均值的概率的上限。
- 公式：对于任意具有有限均值和方差的随机变量 X ，以及任意正数 ε ， $P(|X - E[X]| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$
- 意义：提供了随机变量取值在均值附近的概率下限。
- 作用：是证明弱大数定律的核心工具。

收敛的定义

依概率收敛

对于随机变量序列 $Y_1, Y_2, \dots$ ，若对任意 $\varepsilon > 0$ ： $\lim_{n \rightarrow \infty} P(|Y_n - a| \geq \varepsilon) = 0$
则称 Y_n **依概率收敛**到常数 a 。

以概率1收敛

对于随机变量序列 $Y_1, Y_2, \dots$ ，若： $P(\lim_{n \rightarrow \infty} Y_n = c) = 1$
则称 Y_n **以概率1收敛**（几乎必然收敛）到常数 c 。

两种收敛的关系
以概率1收敛 $\implies$ 依概率收敛 （反之不成立）

	依概率收敛	以概率1收敛
直觉含义	任意时刻偏差概率趋于0	偏差无限次发生的概率为0
强度	较弱	更强

大数定律

描述样本均值**收敛到哪里**：随着样本量增大，样本均值趋近于**真实期望值** μ 。

设 $X_1, X_2, \dots$ 为独立同分布随机变量，均值为 μ ，样本均值为： $M_n = \frac{X_1 + X_2 + \dots + X_n}{n}$

弱大数定律

样本均值**依概率收敛**到 μ ： $\lim_{n \rightarrow \infty} P(|M_n - \mu| \geq \varepsilon) = 0$

强大数定律

样本均值**以概率1收敛**到 μ ： $P(\lim_{n \rightarrow \infty} M_n = \mu) = 1$

弱/强大数定律的本质区别

	弱大数定律	强大数定律
收敛类型	依概率收敛	以概率1收敛（几乎必然）

	弱大数定律	强大数定律
含义	对任意固定 n ，偏差概率趋于0，但偏差仍可能无限次发生	偏差无限次发生的概率严格为 0
强度	较弱	更强
证明工具	切比雪夫不等式	需要更复杂的论证

中心极限定理

与大数定律角度不同：大数定律描述样本均值**收敛到哪里**，中心极限定理描述标准化后的和**服从什么分布**。

- 定义**：大量独立随机变量之和的分布，无论原始分布形态如何，标准化后趋近于标准正态分布。
- 公式**：若 $X_1, X_2, \dots$ 为独立同分布，均值 μ ，方差 σ^2 ，则标准化的和：
$$Z_n = \frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$$

即对所有 z ：
$$\lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z)$$
- 意义**：中心极限定理是统计学中最重要的定理之一，解释了为何现实中大量噪声服从正态分布，为大样本统计推断提供理论基础。
- 基于CLT的正态近似**：将 $S_n = X_1 + \dots + X_n$ 近似视为正态分布
 - 计算均值 $n\mu$ 和方差 $n\sigma^2$
 - 计算标准化值 $z = \frac{c - n\mu}{\sigma\sqrt{n}}$
 - 使用近似：
$$P(S_n \leq c) \approx \Phi(z)$$